TP 3 : Mise en place de l'infrastructure ELK + Spark

Projet fil rouge : Plateforme Big Data d'analyse et de supervision
Travail : Binôme
Évaluation : 10 points
Jalon 1 : Infrastructure technique opérationnelle

1. Contexte

Vous êtes une équipe d'ingénieurs Big Data chargée de développer une plateforme professionnelle permettant à une entreprise de collecter, stocker, traiter, rechercher et visualiser des données.

Au cours des différentes séances de TP, vous allez construire progressivement cette plateforme en utilisant :

- **Elasticsearch** pour le stockage, l'indexation et la recherche ;
- **Logstash** pour l'ingestion et la transformation des données ;
- **Kibana** pour la visualisation et la création de tableaux de bord ;
- **Apache Spark** pour le traitement et l'analyse Big Data.

Votre projet sera réalisé progressivement pendant les **8 séances de TP**.

Chaque séance correspond à un **jalon du projet professionnel**. Le travail réalisé pendant ce TP constituera donc la base technique de toutes les séances suivantes.

2. Mission du TP1

Votre première mission consiste à construire une **infrastructure Big Data fonctionnelle et documentée**.

À la fin de cette séance, votre binôme doit disposer d'une infrastructure permettant de :

- exécuter Elasticsearch sur plusieurs nœuds ;
- accéder à Elasticsearch ;
- utiliser Kibana ;
- exécuter Apache Spark ;
- faire communiquer les différentes machines ;
- effectuer de premières manipulations sur Elasticsearch et Spark.

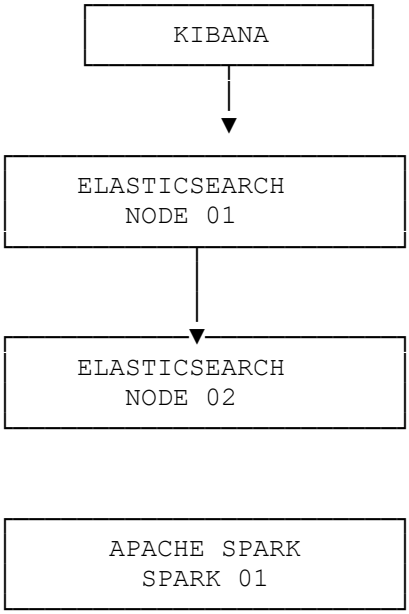
Aucune commande n'est fournie dans cet énoncé.

Vous devez rechercher vous-mêmes les procédures et commandes nécessaires à partir de la documentation technique et des ressources disponibles.

Votre capacité à rechercher, comprendre et appliquer la documentation fait partie de l'évaluation.

3. Architecture cible

Vous devez mettre en place une architecture comportant au minimum les machines suivantes :



Logstash sera ajouté dans l'architecture lors du TP2.

4. Environnement de travail

Vous devez créer et configurer les machines virtuelles nécessaires.

L'architecture minimale demandée est :

Machine	Rôle
ELK-01	Elasticsearch + Kibana
ELK-02	Elasticsearch
SPARK-01	Apache Spark

Vous êtes responsables du choix et de la configuration de :

- la distribution Linux ;
- la version du système ;
- la version des logiciels ;
- la mémoire RAM ;
- le nombre de CPU ;
- l'espace disque ;
- les adresses IP ;
- le réseau virtuel ;

- les paramètres de communication.

Toutes vos décisions techniques devront être **documentées et justifiées dans votre rapport**.

5. Étape 1 : Concevoir votre architecture

Avant de commencer l'installation, concevez l'architecture technique de votre plateforme.

Votre schéma doit présenter clairement :

- les machines virtuelles ;
- leurs rôles ;
- les adresses IP ;
- Elasticsearch ;
- Kibana ;
- Spark ;
- les communications entre les composants.

Votre architecture doit être suffisamment claire pour être présentée à un responsable technique.

Livrable

Un schéma professionnel de l'architecture.

6. Étape 2 : Préparer les machines virtuelles

Créez les machines virtuelles nécessaires à votre architecture.

Configurez leur environnement afin qu'elles puissent communiquer entre elles.

Vous devez notamment mettre en place :

- les noms des machines ;
- les adresses IP ;
- le réseau ;
- la résolution des noms ;
- les paramètres système nécessaires au fonctionnement des logiciels.

Livrable

Complétez le tableau suivant :

Machine	Hostname	Adresse IP	OS	CPU	RAM	Disque	Rôle
ELK-01							
ELK-02							
SPARK-01							

7. Étape 3 : Déployer Elasticsearch

Installez Elasticsearch sur les deux machines prévues.

Les deux nœuds doivent appartenir au **même cluster Elasticsearch**.

Vous devez réaliser vous-mêmes :

- l'installation ;
- la configuration du cluster ;
- la configuration des nœuds ;
- la configuration réseau ;
- la découverte des nœuds ;
- le démarrage des services ;
- la vérification du fonctionnement.

Utilisez une version cohérente d'Elasticsearch sur les deux nœuds.

Votre infrastructure doit permettre de démontrer :

- que les deux nœuds fonctionnent ;
- qu'ils appartiennent au même cluster ;
- qu'ils peuvent communiquer ;
- que le cluster est opérationnel.

Livrables

Dans votre rapport, fournissez :

- la version utilisée ;
- la configuration principale ;
- le nom du cluster ;
- le nom de chaque nœud ;
- les captures d'écran permettant de démontrer le fonctionnement du cluster.

8. Étape 4 : Déployer Kibana

Installez Kibana sur **ELK-01**.

Configurez Kibana afin qu'il puisse communiquer avec votre infrastructure Elasticsearch.

Vous devez être capable d'accéder à l'interface Kibana depuis votre navigateur.

Livrables

Fournissez dans votre rapport :

- la version de Kibana ;

- les principaux paramètres de configuration ;
- une capture de l'interface Kibana ;
- une preuve de connexion avec Elasticsearch.

9. Étape 5 : Réaliser une première manipulation Elasticsearch

Vous devez maintenant démontrer que votre cluster Elasticsearch est réellement opérationnel.

Réalisez une première manipulation métier de votre choix.

Vous devez :

- créer un index ;
- définir ou laisser Elasticsearch déterminer la structure appropriée selon votre choix ;
- insérer plusieurs documents ;
- rechercher les documents ;
- vérifier leur présence dans Elasticsearch.

Utilisez un petit jeu de données cohérent avec un contexte professionnel.

Vous pouvez par exemple travailler avec :

- des produits ;
- des clients ;
- des commandes ;
- des événements ;
- des logs ;
- des transactions.

Le choix des données vous appartient.

Livrables

Fournissez :

- la structure des données ;
- les documents utilisés ;
- les résultats obtenus ;
- les captures d'écran nécessaires.

Cette manipulation constituera le **premier prototype de données** qui sera enrichi lors des prochains TP.

10. Étape 6 : Déployer Apache Spark

Installez Apache Spark sur **SPARK-01**.

Vous devez rechercher vous-mêmes les dépendances nécessaires et réaliser l'installation complète.

Votre environnement doit permettre d'exécuter un premier traitement Spark.

Vous devez également vérifier :

- la version de Java utilisée ;
- la version de Spark ;
- le fonctionnement de l'environnement ;
- l'exécution d'une première application ou d'un premier traitement.

Livrable

Réalisez un petit traitement Spark sur un jeu de données de votre choix.

Présentez :

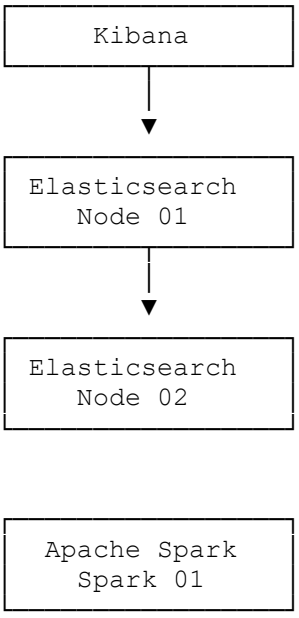
Données → Spark → Résultat

Le jeu de données et le résultat obtenu doivent être intégrés au rapport.

11. Étape 7 :Validation de l'infrastructure

À la fin du TP, vous devez être capables de réaliser une démonstration de votre infrastructure.

Votre démonstration doit montrer :



Vous devez démontrer que chaque composant est :

installé → configuré → démarré → fonctionnel.

12. Rapport professionnel

À la fin du TP, votre binôme doit remettre un rapport au format PDF.

Nom du fichier

TP1_ELK_Spark_NomBinome.pdf

Le rapport doit comporter les sections suivantes :

1. Présentation du projet

Présentez brièvement :

- le contexte ;
- le besoin de l'entreprise ;
- l'objectif de la plateforme ;
- les technologies utilisées.

2. Architecture

Présentez :

- le schéma global ;
- les machines ;
- les rôles ;
- les flux de communication.

3. Environnement technique

Présentez :

- système d'exploitation ;
- versions ;
- CPU ;
- RAM ;
- stockage ;
- réseau ;
- adresses IP.

4. Elasticsearch

Présentez :

- installation ;
- configuration ;

- cluster ;
- nœuds ;
- vérifications ;
- captures d'écran.

5. Kibana

Présentez :

- installation ;
- configuration ;
- connexion à Elasticsearch ;
- interface fonctionnelle.

6. Première manipulation Elasticsearch

Présentez :

- votre jeu de données ;
- votre index ;
- vos documents ;
- vos recherches ;
- vos résultats.

7. Apache Spark

Présentez :

- installation ;
- environnement ;
- version ;
- traitement réalisé ;
- données utilisées ;
- résultat obtenu.

8. Difficultés rencontrées

Pour chaque difficulté, présentez :

Problème → Analyse → Solution → Résultat

9. État final

Présentez un tableau récapitulatif :

Composant	Machine	Version	État
Elasticsearch	ELK-01		Opérationnel / Non opérationnel
Elasticsearch	ELK-02		Opérationnel / Non opérationnel
Kibana	ELK-01		Opérationnel / Non opérationnel

Spark	SPARK-01		Opérationnel / Non opérationnel

13. Évaluation du TP1 :10 points

Critère	Points
Conception de l'architecture	1,5
Mise en place des machines et du réseau	1
Cluster Elasticsearch fonctionnel	2
Configuration et validation des nœuds	1
Kibana fonctionnel	1
Apache Spark fonctionnel	1
Première manipulation Elasticsearch	0,5
Documentation professionnelle	1
Démonstration et maîtrise du travail réalisé	1
Total	**10**

14. Règles du TP

Travail en binôme

Vous êtes responsables collectivement du résultat final.

Les deux membres doivent être capables d'expliquer et de démontrer l'ensemble de l'infrastructure.

Recherche documentaire

Les commandes ne sont volontairement pas fournies.

Vous devez rechercher les informations nécessaires dans la documentation officielle et les ressources techniques fiables.

Vous devez être capables d'identifier :

- la procédure d'installation ;
- les fichiers de configuration ;
- les paramètres nécessaires ;
- les méthodes de vérification ;
- les éventuelles erreurs ;
- les solutions aux problèmes rencontrés.

Qualité professionnelle

Votre travail sera évalué non seulement sur le fait que « cela fonctionne », mais également sur :

- la qualité de l'architecture ;

- la propreté de la configuration ;
- la documentation ;
- la capacité à expliquer vos choix ;
- la qualité des preuves fournies ;
- votre autonomie dans la recherche de solutions.

15. Critère de fin du TP1

Votre **Jalon 1 est validé** lorsque vous pouvez présenter une infrastructure fonctionnelle comprenant :

2 nœuds Elasticsearch + Kibana + Spark

et fournir une documentation permettant à une autre équipe technique de comprendre et de reproduire votre environnement.

Cette infrastructure sera réutilisée et enrichie lors du **TP2 : mise en place de Logstash et du pipeline d'ingestion des données**.