TP 4 : Conception des données et développement d'un pipeline Logstash

Durée : 4 heures
Organisation : Travail en binôme
Évaluation : /10
Jalon 2 : Génération des données, définition du modèle et mise en place d'un pipeline d'ingestion opérationnel.

1. Contexte et objectifs

Dans le cadre de votre projet ELK + Spark, vous devez concevoir et développer une chaîne d'ingestion adaptée à votre propre domaine métier.

Chaque binôme travaille sur un projet distinct et doit générer son propre jeu de données synthétiques. Les données doivent être suffisamment riches pour permettre leur indexation, leur exploration dans Kibana et leur exploitation ultérieure avec Apache Spark.

À la fin de ce TP, vous devez disposer :

- D'un jeu de données synthétiques de qualité, suffisamment volumineux et documenté.
- D'un modèle de données cohérent et d'un mapping Elasticsearch explicite.
- D'un pipeline Logstash capable de transformer, contrôler et indexer les données.
- D'un mécanisme de détection et de traitement des anomalies.
- De preuves chiffrées permettant de vérifier le bon fonctionnement de la chaîne d'ingestion.

2. Contraintes minimales obligatoires

2.1. Données

Votre jeu de données doit respecter les exigences suivantes :

- Au moins **5 000 enregistrements distincts**.
- Au moins **12 champs pertinents**, adaptés à votre domaine.
- Au moins **5 catégories ou modalités métier**, lorsque le domaine le permet.
- Au moins **95 % d'enregistrements conformes** avant l'introduction des anomalies volontaires.
- Au moins **5 % d'enregistrements présentant des anomalies contrôlées**.
- Une diversité de types : identifiants, textes, nombres, catégories, dates ou booléens selon le modèle.
- Un format CSV ou JSON, avec une structure cohérente.
- Une méthode de génération reproductible et documentée.

Les anomalies doivent couvrir au moins quatre catégories différentes : **champs manquants, dates invalides, valeurs numériques incorrectes, catégories inconnues ou autres anomalies pertinentes pour votre domaine.**

Les données réelles confidentielles ou personnelles sont interdites. Vous devez produire des données synthétiques propres à votre projet.

2.2. Modèle Elasticsearch

Le modèle doit comporter un index nommé selon une convention cohérente et un mapping explicite. Les types doivent être adaptés aux opérations de recherche, de filtrage, de tri et d'agrégation.

Vous devez notamment :

- Fournir le fichier de mapping utilisé.
- Justifier les types retenus pour les champs importants.
- Distinguer les champs destinés à la recherche textuelle de ceux utilisés pour les filtres et les agrégations.
- Définir une stratégie de gestion des champs absents, invalides ou inattendus.
- Vérifier que le mapping réellement appliqué correspond au modèle prévu.

Le recours exclusif au typage automatique n'est pas accepté.

2.3. Pipeline Logstash

Le pipeline doit comporter les trois parties suivantes :

- **Input :** lecture de votre propre jeu de données.
- **Filter :** parsing, conversion des types, normalisation et contrôle qualité.
- **Output :** indexation dans Elasticsearch.

La configuration doit être enregistrée dans un fichier réutilisable et documenté.

Le pipeline doit traiter les données, détecter les anomalies et prévoir une stratégie explicite pour les événements rejetés ou en erreur. Les événements invalides ne doivent pas disparaître silencieusement.

2.4. Validation

Vous devez mesurer et présenter :

- Le nombre d'enregistrements générés.
- Le nombre d'événements lus.
- Le nombre d'événements indexés.
- Le nombre d'événements rejetés ou en erreur.
- Le nombre de doublons détectés et leur traitement.
- Les résultats des tests portant sur les quatre catégories minimales d'anomalies.
- La conformité des types de champs dans Elasticsearch.

Tout écart entre les volumes générés, lus, rejetés et indexés doit être expliqué.

2.5. Préparation à Spark

Identifiez au moins **trois traitements analytiques** qui pourront être réalisés dans les prochaines séances avec Spark : un calcul statistique ou une agrégation, une analyse temporelle lorsque le domaine le permet, et une analyse métier adaptée au projet.

Pour chaque traitement, précisez les champs nécessaires et le résultat attendu. L'implémentation complète de ces analyses n'est pas demandée dans ce TP.

3. Travail demandé

Mission 1 : Définition du scénario métier

Choisissez et présentez votre domaine métier, les objectifs du projet, les données nécessaires et les analyses envisagées.

Votre scénario doit être suffisamment précis pour justifier les champs retenus et les choix de conception.

Mission 2 : Génération du jeu de données

Générez un jeu de données synthétiques respectant toutes les contraintes minimales.

Documentez le dictionnaire des données, les règles de génération, les catégories représentées et les anomalies volontairement introduites. Distinguez les anomalies générées des erreurs éventuellement rencontrées pendant l'ingestion.

Mission 3 : Conception du mapping Elasticsearch

Définissez le modèle de données et créez un mapping explicite.

Justifiez les types retenus et vérifiez leur adéquation aux besoins de recherche, de filtrage et d'agrégation. Le mapping doit être livré séparément et son application doit être démontrée.

Mission 4 : Installation et configuration de Logstash

Installez et configurez Logstash dans l'environnement de votre architecture ELK.

Développez un pipeline complet comprenant les parties Input, Filter et Output. Recherchez et exploitez la documentation officielle nécessaire à la configuration, sans vous limiter à une configuration d'exemple non adaptée à votre projet.

Mission 5 : Transformation et ingestion des données

Configurez le pipeline pour lire les données, convertir les types, normaliser les valeurs et contrôler leur validité.

Le traitement doit inclure au minimum quatre catégories d'anomalies, avec une stratégie documentée pour chaque catégorie. Assurez-vous que les événements valides sont indexés et que les événements problématiques sont identifiables et comptabilisés.

Mission 6 : Vérification dans Elasticsearch et Kibana

Vérifiez l'index, les documents, les types de champs et les volumes obtenus.

Utilisez Kibana pour explorer les données et produire des visualisations pertinentes. Présentez un bilan chiffré des événements générés, lus, indexés, rejetés et dupliqués. Expliquez les écarts constatés.

Mission 7 : Préparation du prochain jalon

Présentez trois traitements analytiques envisagés avec Spark, les champs nécessaires et les résultats attendus.

Identifiez également les limites de votre jeu de données et les améliorations à apporter lors du prochain TP.

4. Livrables attendus

Déposez un dossier nommé `TP2_ELK_Spark_NomBinome` contenant :

1. Le jeu de données synthétiques complet d'au moins 5 000 enregistrements.
2. Le dictionnaire des données et la documentation de génération.
3. Le fichier de mapping Elasticsearch.
4. Le fichier de configuration Logstash complet et réutilisable.
5. Un rapport PDF professionnel présentant le scénario, les choix techniques, les tests et les résultats.
6. Des captures d'écran authentiques de l'exécution du pipeline, de l'index Elasticsearch et des vérifications dans Kibana.
7. Un tableau récapitulatif des volumes générés, lus, indexés, rejetés et dupliqués.
8. La description des anomalies testées et du traitement appliqué.
9. La proposition de trois traitements analytiques destinés à Spark.

Le rapport doit permettre à un autre binôme de comprendre votre solution et de reproduire votre configuration dans un environnement comparable.

5. Critères d'évaluation

Critère	Points
Scénario métier et pertinence du besoin	1
Qualité, volume et diversité des données	1,5
Modèle de données et mapping Elasticsearch	1,5
Installation et configuration de Logstash	1
Fonctionnalité et qualité du pipeline	2
Gestion des anomalies et validation chiffrée	1

Rapport et preuves de réalisation	1
Démonstration et maîtrise individuelle	1
Total	**10**

6. Conditions de validation

Le respect des contraintes minimales est obligatoire. Une simple lecture de fichier suivie d'une indexation directe ne suffit pas à valider le TP.

Les fichiers livrés doivent correspondre aux résultats présentés. Les captures d'écran ne remplacent ni les données ni les configurations. Chaque membre du binôme doit être capable d'expliquer les choix de mapping, les transformations, la gestion des anomalies et les résultats obtenus.

La maîtrise individuelle pourra conduire à une différenciation des notes au sein **d'un même binôme**.

Préparation du TP 3 : vous réutiliserez votre jeu de données et votre pipeline pour renforcer la fiabilité de l'ingestion, tester des volumes plus importants et préparer les données aux traitements distribués avec Spark.